

Análise Bioestatística da Retinopatia Diabética

Arianny Leão

11 de setembro de 2026

1 Descrição do dataset e metodologia de seleção

A doença escolhida foi a Retinopatia Diabética (RD). Em vez de adotar diretamente o primeiro dataset encontrado, optei por realizar uma etapa adicional de seleção. No notebook `00_dataset_comparison.ipynb` foram comparados seis datasets: mBRSET, BRSET, Diabetic Retinopathy Debrecen, DRS, ODIR-5K e CMRDD. Os datasets foram submetidos à mesma inspeção, incluindo validações de dimensionalidade, tipos, valores ausentes, variáveis clínicas e demográficas, pares numéricos para correlação, grupos válidos e desfecho relacionado à RD.

A escolha seguiu três etapas objetivas: (1) **elegibilidade científica**, exigindo proveniência institucional verificável, o CMRDD atendeu aos seis critérios estatísticos, mas foi excluído por não ter documentação científica independente; (2) **cobertura dos requisitos**, na qual mBRSET e BRSET empataram com 6/6 critérios, contra 5/6 do DRS, 4/6 do ODIR-5K e 3/6 do Debrecen (esse último é composto por atributos extraídos de imagem, sem variáveis clínicas); (3) **desempate objetivo**, favorecendo o mBRSET por apresentar mais pares numéricos utilizáveis em correlação (3 vs. 1), mais variáveis de agrupamento válidas (8 vs. 7) e mais variáveis clínicas estruturadas (14 vs. 4). No paridade/duração do diabetes do mBRSET havia, em nível de imagem antes da agregação por paciente, 5.108 registros completos (98,9% da base), o que reforçou sua adequação à análise de correlação exigida pela atividade.

O **mBRSET (Mobile Brazilian Retinal Dataset)** [1, 2] contém 5.164 imagens de fundo de olho de 1.291 pacientes diabéticos brasileiros (4 imagens/paciente), com 24 colunas de metadados clínicos e demográficos, incluindo idade, sexo, escolaridade, duração do diabetes, uso/duração de insulina, hipertensão, tabagismo, obesidade, comorbidades vasculares/renais/neurológicas, classificação ICDR (0 - 4) [4] e edema macular. A documentação reporta kappa ponderado de 0,863 entre especialistas na classificação ICDR. Lembrando que o acesso aos arquivos do mBRSET no PhysioNet exige credenciamento, nesta análise foi utilizado o arquivo tabular disponibilizado no repositório GitHub dos autores [3].

2 Metodologia de pré-processamento

O notebook `01_diabetic_retinopathy_analysis.ipynb` concentra a análise principal, seguindo as decisões abaixo, na ordem aplicada:

1. **Duplicidade:** nenhuma duplicata exata nas 5.164 linhas originais;
2. **Padronização de tipos:** variáveis numéricas convertidas; variáveis binárias normalizadas para 0/1, sem perda de valores válidos.
3. **Faixas plausíveis:** idade entre 0 - 120 anos; durações ≥ 0 ; escolaridade entre 1 - 7; ICDR entre 0 - 4. Nenhum registro violou esses limites isoladamente.
4. **Inconsistências lógicas entre variáveis:** apenas o valor inconsistente foi convertido em NaN. Foram identificados 8 registros com duração do diabetes maior que a idade e 8 com duração de insulino-terapia maior que a duração do diabetes.
5. **Ausência estrutural vs. real na variável `insulin_time`:** entre os 4.052 registros sem uso de insulina, 100% têm essa variável ausente (por não-aplicabilidade e não falta de preenchimento); entre os usuários de insulina, 1.008 têm o tempo preenchido e 56 apresentam ausência genuína.
6. **Consistência intrapaciente:** verificou-se se as 4 imagens de cada paciente divergiam nas variáveis clínicas/demográficas repetidas. Nenhum conflito foi encontrado, permitindo a agregação sem necessidade de regra de desempate.
7. **Agregação para nível de paciente:** numéricas resumidas pela mediana, categóricas pela moda; o estágio ICDR do paciente recebeu o maior estágio entre as imagens com classificação disponível, como decisão analítica adotada nesta atividade; edema marcado quando presente em ao menos uma imagem. Resultado: 1.291 pacientes $\times$ 23 colunas.
8. **Validação externa:** idade média (61,45 anos) e % feminino (65,07%) obtidos após agregação coincidiram com os valores publicados no artigo original do mBRSET (61,44 anos; 65,06%) [1], fornecendo uma verificação adicional da consistência da agregação.
9. **Sem imputação geral:** cada procedimento usa apenas casos completos das variáveis envolvidas. A variável de tempo de insulina é analisada só entre os 252 pacientes em insulino-terapia com essa informação disponível. Na tabela por paciente, 80,48% dos valores dessa variável estão ausentes, principalmente por não aplicabilidade aos pacientes que não utilizam insulina.

3 Análise exploratória e caracterização da amostra

A amostra final tem 1.291 pacientes (Tabela 1). A idade tem maior dispersão absoluta (DP = 11,64 anos), mas duração do diabetes (CV = 88,57%) e de insulinoterapia (CV = 102,83%) são relativamente mais variáveis que a idade (CV = 18,94%).

Tabela 1: Estatística descritiva das variáveis numéricas por nível de paciente.

Variável	n	Média	Mediana	DP	Mín.	Máx.	CV(%)
Idade (anos)	1.291	61,45	63,0	11,64	3	110	18,94
Duração diabetes (anos)	1.275	9,48	7,0	8,40	0	50	88,57
Duração insulina (anos) ^a	252	7,76	5,0	7,98	0	50	102,83

^a Restrita a pacientes em uso de insulina com essa informação disponível.

Os percentuais categóricos a seguir utilizam a amostra total de 1.291 pacientes como denominador, mantendo os valores ausentes no cálculo das frequências relativas. 65,07% dos pacientes são do sexo feminino; escolaridade mais frequente: ensino fundamental incompleto (41,75%); hipertensão em 70,80%; tratamento oral em 83,89%; uso de insulina em 20,60%; edema macular em 12,08%. A classificação ICDR estava disponível para 1.287/1.291 pacientes (Tabela 2): 69,3% foram classificados como sem RD. Entre os estágios de RD, a RDNP moderada foi a categoria mais frequente, correspondendo a 15,5% dos pacientes classificados, enquanto a RDNP grave foi a menos frequente, com 2,2%.

Tabela 2: Distribuição do maior estágio ICDR por paciente (n = 1.287).

Estágio ICDR	n	%
0: Sem RD	892	69,3
1: RDNP leve	96	7,5
2: RDNP moderada	200	15,5
3: RDNP grave	28	2,2
4: RD proliferativa/estado pós-laser	71	5,5

4 Visualizações

Foram produzidos quatro gráficos, os três centrais são reproduzidos abaixo.




Figura 1: Esquerda: histograma da idade, com média e mediana próximas (61,4 e 63,0 anos), concentração entre 50–75 anos. Centro: distribuição do maior estágio ICDR (n=1.287), evidenciando forte desbalanceamento de grupos. Direita: boxplot da duração do diabetes por estágio ICDR, com tendência de aumento das medianas nos estágios mais avançados, mas sobreposição relevante entre os grupos.

No notebook, um quarto gráfico de dispersão entre idade e duração do diabetes complementa a análise de correlação.

5 Análise estatística

5.1 Correlação: idade $\times$ duração do diabetes

H0: $\rho_s = 0$; **H1:** $\rho_s \neq 0$; $\alpha = 0,05$. O teste de Shapiro-Wilk [5] rejeitou a normalidade de ambas as variáveis ($n = 1.275$, $p < 0,05$), fundamentando o uso da correlação de Spearman [6]. Resultado: $\rho_s = 0,220$ (IC95% bootstrap com 2.000 reamostragens [7]: 0,165 a 0,273; $p = 2,24 \times 10^{-15}$). **Conclusão:** rejeita-se H0: há associação positiva estatisticamente significativa, porém de baixa magnitude. O gráfico de dispersão demonstra a tendência com ampla dispersão dos pontos: pacientes de idade semelhante podem ter durações do diabetes muito diferentes, o que reforça que significância estatística não equivale a associação clinicamente forte.

5.2 Comparação entre grupos: duração do diabetes por estágio ICDR

H0: a duração do diabetes se distribui igualmente entre os cinco estágios ICDR; **H1:** pelo menos um estágio apresenta distribuição diferente; $\alpha = 0,05$. Como o Shapiro-Wilk rejeitou a normalidade em 4 dos 5 grupos e o teste de Levene com centragem na mediana (sendo equivalente ao teste de Brown-Forsythe [9]) indicou heterogeneidade de variâncias ($p = 0,0094$), optou-se pelo Kruskal-Wallis [8]. Resultado: $H = 167,70$, $p = 3,26 \times 10^{-35}$. **Conclusão:** rejeita-se H0.

Como o teste global não indica quais pares diferem, aplicou-se o teste de Mann-Whitney [10] par a par, totalizando 10 comparações, com correção de Holm [11] para controle do erro associado às múltiplas comparações (Tabela 3). Após a correção, não foram encontradas diferenças estatisticamente detectáveis apenas entre Sem RD e RDNP leve com $p = 0,152$ e entre RDNP moderada e RDNP grave com $p = 0,925$.

Tabela 3: Comparações pós-hoc da duração do diabetes entre os estágios ICDR.

Comparação	p ajustado (Holm)	Resultado
Sem RD $\times$ RDNP leve	0,152	Não significativo
Sem RD $\times$ RDNP moderada	$< 0,001$	Significativo
Sem RD $\times$ RDNP grave	$< 0,001$	Significativo
Sem RD $\times$ RD proliferativa	$< 0,001$	Significativo
RDNP leve $\times$ RDNP moderada	$< 0,001$	Significativo
RDNP leve $\times$ RDNP grave	0,038	Significativo
RDNP leve $\times$ RD proliferativa	$< 0,001$	Significativo
RDNP moderada $\times$ RDNP grave	0,925	Não significativo
RDNP moderada $\times$ RD proliferativa	$< 0,001$	Significativo
RDNP grave $\times$ RD proliferativa	0,022	Significativo

Teste de Mann-Whitney com ajuste de Holm para múltiplas comparações ($\alpha = 0,05$).

6 Interpretação dos resultados e limitações

Características da população: predominantemente feminina (65,1%), idade média 61,45 anos, maioria sem RD entre os classificados. **Variabilidade:** duração de insulino terapia e do diabetes são relativamente mais variáveis que a idade (CV), embora que a idade tenha maior dispersão absoluta. **Associações observadas:** idade e duração do diabetes estão associadas de forma positiva, significativa, porém fraca, o que não implica causalidade. **Diferenças entre grupos:** a duração da diabetes diferiu entre a maioria dos pares de estágios ICDR. Após a correção de Holm, não foram encontradas diferenças estatisticamente detectáveis apenas entre Sem RD e RDNP leve e entre RDNP moderada e RDNP grave. **Significância vs. relevância clínica:** as duas análises inferenciais principais apresentaram evidência estatística ao nível de 5%. Entretanto, duas comparações pós-hoc não apresentaram diferenças estatisticamente detectáveis. Além disso, a correlação de baixa magnitude e a sobreposição observada no boxplot mostram que significância estatística não implica, isoladamente, relevância clínica.

Limitações: (i) o estágio ICDR do paciente foi definido pelo maior valor entre as imagens com classificação disponível, sendo essa uma decisão analítica e não um rótulo oficial do dataset em nível de paciente; (ii) na comparação da duração do diabetes, os grupos ICDR apresentam tamanhos bastante desiguais, variando de 28 a 878 pacientes; (iii) comorbidades autorreferidas, sujeitas a erro de informação; (iv) ausência de controle de fatores de confusão; (v) resultados restritos aos pacientes do mBRSET, obtidos em um contexto específico de coleta no Brasil, sem generalização direta para outras populações ou inferência causal.

7 Conclusão

A análise de 1.291 pacientes do mBRSET, precedida por uma comparação objetiva de seis datasets candidatos, mostrou uma população predominantemente feminina com idade média de 61,45 anos e, entre os classificados, predominância de ausência de RD. Idade e duração do diabetes apresentaram associação positiva de baixa magnitude ($\rho_s = 0,220$; IC95%: 0,165–0,273). O teste de Kruskal-Wallis indicou diferenças na distribuição da duração do diabetes entre os estágios ICDR ($p < 0,001$). Nas comparações pós-hoc de Mann-Whitney com correção de Holm, 8 dos 10 pares apresentaram diferenças estatisticamente detectáveis, com exceção de Sem RD $\times$ RDNP leve e RDNP moderada $\times$ RDNP grave. Os achados descrevem exclusivamente os pacientes do mBRSET e não permitem extrapolação causal ou populacional.

Reprodutibilidade e fontes.

Código-fonte completo, com os dois notebooks documentados passo a passo: <https://github.com/ariwired/dr-statistical-analysis>. O arquivo 00_dataset_comparison.ipynb corresponde à etapa complementar de seleção do dataset, enquanto 01_diabetic_retinopathy_analysis.ipynb contém a análise principal desenvolvida para a atividade.

Referências

- [1] Wu, C. et al. A portable retina fundus photos dataset for clinical, demographic, and diabetic retinopathy prediction. *Sci Data*, 12, 323, 2025. DOI.
- [2] Nakayama, L.F. et al. mBRSET, a Mobile Brazilian Retinal Dataset (v1.0). PhysioNet, 2024. PhysioNet.
- [3] Nakayama, L.F. mBRSET. GitHub, 2024. GitHub.
- [4] Wilkinson, C.P. et al. Proposed international clinical diabetic retinopathy and diabetic macular edema disease severity scales. *Ophthalmology*, 110(9), 2003. Artigo.
- [5] Shapiro, S.S.; Wilk, M.B. An analysis of variance test for normality. *Biometrika*, 52, 1965. PDF.
- [6] Spearman, C. The Proof and Measurement of Association between Two Things. *The American Journal of Psychology*, 15(1), 1904. DOI.
- [7] Efron, B. Bootstrap Methods: Another Look at the Jackknife. *The Annals of Statistics*, 7(1), 1979. PDF.
- [8] Kruskal, W.H.; Wallis, W.A. Use of Ranks in One-Criterion Variance Analysis. *JASA*, 47(260), 1952. DOI.
- [9] Brown, M.B.; Forsythe, A.B. Robust Tests for the Equality of Variances. *JASA*, 69, 1974. Artigo.
- [10] Mann, H.B.; Whitney, D.R. On a Test of Whether one of Two Random Variables is Stochastically Larger than the Other. *Annals of Mathematical Statistics*, 18, 1947. Artigo.
- [11] Holm, S. A Simple Sequentially Rejective Multiple Test Procedure. *Scandinavian Journal of Statistics*, 1979. PDF.